

Analisi e Commento del Dataset Communities and Crimes

Filippo Antico, Milo Bizzotto, Marta Boschetto, Sara Guzzo

1 Introduzione

Il dataset *Communities and Crimes*, [3] contiene 2215 osservazioni di comunità statunitensi su cui sono state rilevate 147 variabili. Queste sono il risultato di una combinazione di dati socio-economici raccolti tramite il censimento statunitense, dati sulle forze dell'ordine provenienti dall'indagine LEMAS, [1] e dati sulla criminalità provenienti dall'indagine UCR, [2] condotta dall'FBI.

L'obiettivo dell'analisi è studiare eventuali relazioni tra variabili e verificare se alcune di esse abbiano un effetto significativo sul tasso di criminalità nelle varie comunità al fine di prevederlo.

Si precisa che l'analisi è svolta con il software R, con la seguente versione: *R version 4.5.3*
Copyright (C) 2026 The R Foundation for Statistical Computing.

2 Pre-Processing

Come primo passo sono stati identificati gli NA nel dataset. Si nota, nella maggior parte delle comunità, la presenza di *missing values* sulle variabili relative al *LEMAS*. Ciò è dovuto al fatto che, nella somministrazione di tale questionario, sono stati presi in considerazione solamente dipartimenti di polizia con almeno 100 agenti e un piccolo campione casuale di dipartimenti più piccoli; le comunità non presenti né nei dati del censimento né nei dataset sulla criminalità sono state escluse. Per tali motivi, si è optato di eliminare del tutto dall'analisi del dataset le variabili *LEMAS*. Inoltre, sono state rimosse anche variabili considerate “ridondanti” oppure derivanti dalla combinazione di altre colonne (ad esempio, per le variabili con codifica sia in valore assoluto che in percentuale, si è scelto di tenere quest'ultima).

E' stata aggiunta la variabile *rip* relativa alla ripartizione geografica degli USA in 4 zone: Midwest, Sud, Nord-Est e Ovest. Si noti che gli Stati di Alaska, Hawaii, Montana e Nebraska non sono considerati nell'analisi per mancanza di osservazioni. Sono state aggiunte anche 4 variabili binarie come indicatrici delle ripartizioni.

Dopo questa prima fase di pulizia, gli NA rimanenti nel dataset erano presenti soprattutto nella colonna relativa al tasso di violenze sessuali e, di conseguenza, anche nella variabile del tasso di criminalità totale. Pertanto, si è deciso di stimare *rapesPerPop* tramite l'algoritmo *k-nearest neighbours*. La procedura, applicata a uno Stato alla volta, è la seguente: prima sono stati rimossi tutti gli NA dal dataset; successivamente, in *rapes* e *rapesPerPop*, tutte le osservazioni sono state sostituite con valori NA; infine, applicando l'algoritmo *KNN*, sono state usate tutte le altre covariate per prevedere le suddette variabili. L'eliminazione dei reali valori attuata nella procedura ha permesso di calcolare gli scarti tra il valore reale delle osservazioni e la stima ottenuta con l'algoritmo. Per la scelta di quanti “vicini” utilizzare nel *KNN*, si sono considerati valori di *k* da 1 a 100 per ogni Stato e si è trovato il parametro che minimizzasse l'MSE di ricostruzione per ognuno di essi. Sono stati poi confrontati i 44 *k* ottenuti e, tramite valutazioni grafiche, si è individuato che *k*=8 fosse un valore appropriato per la maggior parte degli Stati. La performance dell'algoritmo è stata valutata solo sulla previsione delle due variabili relative agli stupri, in quanto

quelle con maggior numero di NA, ma si assume che la procedura funzioni similmente anche per gli altri crimini in cui vi erano NA. Il tasso di criminalità *ViolentCrimesPerPop* finale è dato dalla somma dei singoli tassi di crimini violenti; per quelli in cui vi erano NA si sono usate le stime di *KNN*. Si fa presente che nella modellazione successiva delle variabili per prevedere la risposta, tutte le variabili relative a crimini violenti sono state escluse in quanto la risposta ne era linearmente dipendente. Si precisa che alla riga 2006 del dataset mancava la variabile *OtherPerCap*; pertanto, essa è stata imputata con la media.

3 Analisi Esplorative

Le unità statistiche sono le comunità americane identificate dal proprio nome, dal nome dello Stato di appartenenza, dal codice della contea e da quello della comunità.

Per favorire l'analisi esplorativa, le variabili sono state suddivise nei seguenti sottogruppi:

1. colonne da 4 a 13, caratteristiche demografiche
2. colonne da 14 a 28, variabili socio-economiche
3. colonne da 29 a 38, istruzione e condizione lavorativa
4. colonne da 39 a 49, status familiare
5. colonne da 50 a 59, immigrazione e lingua
6. colonne da 60 a 92, Condizioni abitative
7. colonne da 93 a 102, crimini

3.1 Caratteristiche demografiche

Il numero totale di abitanti nelle comunità è di 117 milioni, concentrati principalmente nella regione occidentale. A livello etnico, il gruppo più rilevante è quello caucasico (68% della popolazione), seguito dalle comunità afro-americana (16%), ispanica (12%) ed asiatica (4%). Per le età, il dataset si affida a 4 classi: [12-21], [12-29], [16-24], [65 o più]. Ovviamente, data la sovrapposizione delle classi, la correlazione tra queste variabili risulta elevata e con coefficiente positivo.

3.2 Variabili socio-economiche

In generale, le condizioni socio-economiche tra le quattro macroaree geografiche sopra citate sono disomogenee.

Per quanto riguarda le condizioni abitative, l'89% della popolazione vive in zone urbane. Il 15% della popolazione vive al di sotto della soglia di povertà, stato che affligge in particolare i paesi del sud, mentre a nord-est si registra il reddito familiare mediano più alto. Si presenta in Fig. 1 la distribuzione del reddito pro capite globale per etnia; si osserva un evidente gap tra americani caucasici e i gruppi di minoranza (soprattutto afro-americani ed ispanici). Ripetendo l'analisi all'interno delle quattro ripartizioni geografiche, si nota il medesimo pattern.




Figura 1: Boxplot delle variabili relative al reddito pro capite per ogni etnia.

Le percentuali di famiglie con reddito da lavoro dipendente e di famiglie con reddito derivante dalla previdenza sociale sono significativamente correlate ($p\text{-value} < 0,001$, $\rho = -0,90$).

3.3 Istruzione e condizione lavorativa

Per quanto riguarda l'istruzione, il livello è basso prevalentemente negli stati del Sud: gli abitanti degli stati meridionali che non hanno raggiunto un grado di istruzione superiore alla terza media e che non sono diplomati sono rispettivamente il 3% e il 7%. Negli stati occidentali, invece, dove il livello di istruzione è più elevato, il 6,5% ha conseguito un titolo di laurea "undergraduate" o di grado superiore. Il tasso di disoccupazione rilevato nel campione è pari al 7%; inoltre, si può notare una correlazione tra le variabili relative ai vari settori occupazionali della forza-lavoro.

3.4 Status familiare

La sezione riporta le caratteristiche familiari delle varie comunità statunitensi, tra cui tassi di divorzio, solitudine e composizione delle famiglie. Ragionevolmente, le variabili più correlate tra loro sono i tassi di uomini e donne divorziati, tutte le variabili relative al numero e all'età dei figli di coppie sposate, e le percentuali di madri lavoratrici e madri lavoratrici con infanti. Si nota invece una correlazione negativa tra il numero di unioni matrimoniali e il numero di figli nati da coppie non sposate. Una valutazione grafica permette inoltre di notare che le comunità dell'Ovest sono caratterizzate da famiglie meno numerose, con un numero di figli inferiore rispetto al resto degli USA. Le altre regioni, invece, si comportano in maniera tra loro uniforme.

3.5 Immigrazione e lingua

A livello nazionale, l'11% della popolazione è nata all'estero, di cui ben il 5% è situato negli stati occidentali. Il grafico in Fig. 2 mostra la quota di immigrati recenti (il periodo considerato è l'ultimo decennio) sulla popolazione residente per stato. Dall'analisi si nota un'alta concentrazione di immigrati in California, con una quota media del 2.39%, seguita da New York con una quota di

0.87%, poi Texas con 0.47%, New Jersey con 0.29% e Florida con 0.23%.

Si nota subito che la California spicca per l'elevata immigrazione. Più in generale, la quota di immigrati maggiore si registra a Sud e Nord-Est, mentre è più ridotta al centro e al Nord del paese.




Figura 2: Grafico della quota di immigrati recenti (ultimi 10 anni) sulla popolazione divisa per stato.

3.6 Condizioni abitative

Per quanto riguarda le condizioni abitative e la qualità della vita, il 5% della popolazione vive in abitazioni con più di 6 individui. Si nota un'elevata correlazione interna tra le variabili relative alla condizione abitativa (numero di stanze, numero di inquilini per edificio, numero di edifici abitati e le caratteristiche di queste ultime). Infine, vi è alta correlazione tra il numero di persone senzatetto rilevate nelle strade e il numero delle stesse nei rifugi ($\rho=0.95$), e tra tutte le variabili relative allo stato di nascita e residenza.

3.7 Crimini

Si prendono infine in considerazione le variabili relative ai crimini violenti e non violenti, espressi come tassi su 100 mila persone. Dal diagramma a barre in Fig. 3 si nota che il tasso *ViolentCrimesPerPop* è influenzato maggiormente dal tasso di violenze sessuali e aggressioni.

Inoltre, si presentano in Fig. 4 e Fig. 5 i grafici delle reti tra stati, dove la dimensione dei nodi è dovuta alla quota di crimini violenti nello Stato, mentre la sfumatura di rosso dell'arco indica la somiglianza a livello di covariate. Come visibile in Fig. 4, la California è la regione più criminosa, seguita da Texas, Florida, New Jersey, Michigan e Massachusetts.




Figura 3: Diagramma a barre delle variabili relative a crimini violenti e non violenti




Figura 4: Rete sulla mappa degli Stati Uniti d'America.




Figura 5: Rete del Nord-Est degli Stati Uniti d'America.

3.8 Analisi bivariata

Per completare l'analisi esplorativa, si prendono in esame alcune correlazioni tra il tasso di criminalità (*ViolentCrimesPerPop*) e variabili selezionate da cinque macroaree: reddito, livello di istruzione, immigrazione, caratteristiche familiari e povertà. Tutte le correlazioni riportate sono state valutate con il test di Spearman e sono risultate significative ($p\text{-value} < 0.001$).

Per quanto riguarda il reddito, si osserva una correlazione negativa significativa con *medIncome* pari a -0,4; dunque, alla diminuzione del reddito medio corrisponde un aumento dei crimini violenti. Relativamente all'istruzione, si notano moderate correlazioni, pari a 0.4 e 0.5, di *PctLess9thGrade* e *PctNotHSGrad* con il tasso di criminalità, mentre risultano deboli le correlazioni con l'immigrazione. Risultano invece più rilevanti le correlazioni con le caratteristiche familiari; infatti, sono presenti elevate correlazioni negative (-0.74 e -0.71) tra tasso di criminalità e percentuale di bambini con due genitori, o similmente con la percentuale di famiglie composte da 2 genitori (*PctKids2Par* e *PctFam2Par*). Il risultato è coerente con una correlazione positiva (0.75) tra il tasso e la percentuale di bambini nati da madri mai sposate (*PctKidsBornNeverMar*). Infine, per la povertà si osserva una correlazione leggermente positiva (0.60 e 0.53) con le variabili relative alle famiglie che ricevono assistenza pubblica (*PctWPubAsst*) e che vivono sotto la soglia di povertà (*PctPopUnderPov*), andando a confermare il legame tra disagio economico e criminalità.

Date le informazioni estratte dall'analisi esplorativa, si procede alla valutazione di vari modelli per il nostro dataset.

4 Applicazione e valutazione di modelli previsivi

Come approccio modellistico a fine previsivo di *ViolentCrimesPerPop*, sono stati valutati i seguenti modelli:

- Modello lineare classico,
- Modello lineare applicato agli scores della *Principal Component Analysis*,
- Regressione lineare con approcci *stepwise backward*, *forward* ed ibrido;

Dati i risultati dell'analisi esplorativa, si sospetta multicollinearità tra gran parte delle variabili. Si è perciò deciso di applicare i metodi Ridge, Lasso ed Elastic Net (Fig. 6), quest'ultimo con

approccio *k-fold cross-validation*. Si sono considerati sia il lambda minimo che quello distante uno standard error dal minimo, come riportato in Fig. 7.

Il dataset iniziale è stato suddiviso in un training set per adattare il modello ed un testing set, su cui la performance predittiva di tutti i metodi statistici è stata valutata tramite MSE. Solamente per i modelli lineari senza penalizzazione Ridge o Lasso, si è calcolato l'AIC, ma per la scelta del miglior modello si è considerato esclusivamente il minimo errore quadratico medio¹.

Si riportano in Tab. 1 i risultati degli MSE dei modelli:

Modello	MSE
Modello lineare con PCA	128584.2
Elastic Net (λ 1se)	157291.7
Elastic Net (λ min)	179093.3
Stepwise Both (lm0)	183427.3
Minimi Quadrati	187841.6
Stepwise Forward	187845.5
Stepwise Backward	189638.7
Stepwise Both (lm1)	189638.7
Lasso	193341.3
Ridge	193439.9

Tabella 1: Confronto MSE tra modelli di regressione (in giallo i migliori 3).

Il modello lineare applicato agli scores della *Principal Component Analysis* risulta il migliore della tabella; tuttavia, si è preferito utilizzare l'Elastic Net (secondo per MSE) in quanto più facilmente interpretabile.

4.1 Interpretazione del modello

Le variabili che influenzano direttamente (coefficienti β positivi) il tasso di crimini violenti risultano essere le percentuali di persone che abitano in zone urbane e di individui che ricevono assistenza pubblica. Dal punto di vista dello status familiare e abitativo, il tasso cresce assieme alle percentuali di maschi divorziati e di figli nati da coppie non sposate. Lo stesso avviene anche per il numero di senzatetto in rifugio e la percentuale di case non occupate. Tutto ciò può essere l'espressione di disuguaglianze create da un disagio economico e da fragilità familiari che, come riportato nella Sez. 3.8, risultano legati alla criminalità. Le variabili che agiscono inversamente sui crimini, invece, sono le percentuali di caucasici nella popolazione, di figli con due genitori, di madri lavoratrici e di case abitate. Questi fattori rappresentano una condizione economica, abitativa e familiare più stabile, che sfavorisce lo sviluppo di un contesto criminale.

¹Si noti che il confronto non è perfettamente equo, in quanto alcuni modelli sono basati sulle variabili originarie e altri sulle componenti principali.




Figura 6: Shrinkage dei coefficienti del modello Elastic Net.




Figura 7: MSE in funzione di log-lambda

5 Classificazione

Successivamente, si è deciso di attribuire un livello di pericolosità alle comunità del dataset tramite i seguenti metodi di classificazione:

- *Linear Discriminant Analysis*,
- *Quadratic Discriminant Analysis*,
- CART;

Per questa procedura, *ViolentCrimesPerPop* è stata trasformata in una variabile categoriale a tre livelli (*Basso*, *Medio*, *Alto*). La scelta delle soglie per la suddivisione in classi è stata effettuata arbitrariamente: il rischio di criminalità è *basso* per valori < 250 , *medio* per valori compresi tra 250 e 1000 e *alto* per valori superiori. Il criterio utilizzato per le categorie è la semplificazione delle interpretazioni.

Le performance di tutti e tre i metodi sono riassunte tramite i grafici delle curve ROC (Fig. 8) e le rispettive AUC (Tab.2).




Figura 8: Grafici delle 3 curve ROC.
0 = *Basso*, 1 = *Medio*, 2 = *Alto*

Modello	0/1	0/2	1/2
LDA	0.862	0.985	0.668
QDA	0.856	0.967	0.549
CART	0.833	0.959	0.588

Tabella 2: Confronto AUC tra modelli. 0 = *Basso*, 1 = *Medio*, 2 = *Alto*

I risultati riportati in Tab. 2 suggeriscono che il criterio di classificazione più performante per il dataset è la LDA. Si osserva che le classi *basso* ed *alto* sembrano ben separate tra loro dal modello ($AUC > 0.9$), mentre non si può dire altrettanto della suddivisione tra *medio* e *alto*. Si ipotizza che la difficoltà nella previsione sia dovuta alla somiglianza tra i due gruppi e al fatto che la distribuzione del tasso sia altamente asimmetrica (come si osserva in Fig. 9) e si concentri su valori bassi (in un'analisi nazionale, le zone ad alto rischio di crimine saranno sicuramente meno numerose rispetto a quelle sicure).

5.1 Classificazione Binaria

Si procede quindi con una classificazione binaria nei soli livelli *basso* ed *alto*, al fine di indagare l'eventuale miglioramento della performance. I risultati sono osservabili in Fig. 10 con i relativi valori dell'AUC nella Tab.3.

Ancora una volta, sia la valutazione grafica delle curve che il confronto tra i valori in tabella ci confermano il miglior adattamento della LDA. In Fig. 11, viene riportata la suddivisione degli Stati ad alto e basso rischio, basandosi sulla classificazione appena effettuata. Come suggerito in precedenza dall'analisi esplorativa, è chiaramente osservabile come gli Stati del sud e dell'ovest siano i più criminali, ai quali si aggiungono poi anche New York e Michigan. Al contrario, le aree più sicure sembrano essere il Mid-West ed il Nord-Est.




Figura 9: Istogramma del tasso di criminalità (*ViolentCrimesPerPop*).

Modello	AUC
LDA	0.911
QDA	0.894
CART	0.871

Tabella 3: Confronto AUC con classificazione binaria.




Figura 10: Grafico della Curva ROC con classificazione binaria.




Figura 11: Mappa degli Stati Uniti classificati in base al rischio (alto=rosso, basso=verde).

6 Conclusioni

L'analisi esplorativa di questo dataset ha fornito importanti suggerimenti sulla struttura delle variabili di interesse, che si sono poi dimostrate coerenti con le interpretazioni dei modelli e con la ripartizione delle aree di rischio. Come ci si aspettava, l'elevata densità abitativa, determinati problemi di isolamento sociale (divorzi, vagabondaggio, assenza di un nucleo familiare, ecc.) e le difficoltà economiche sono tutti fattori che contribuiscono ad aumentare la propensione al crimine di una popolazione. D'altra parte, l'indagine sottolinea come, al fine di ridurre i tassi di delitti, sia necessario effettuare decisioni atte a favorire l'integrazione etnica e a ridurre la precarietà economica e sociale.

L'analisi della LDA, riassunta nella Fig. 11, ci permette di notare pattern coerenti con quanto appena detto: gli Stati con i maggiori tassi di criminalità sono quelli del Sud, caratterizzati da elevati tassi di immigrazione e dalla quasi totale assenza di politiche di previdenza sociale. California, New York e Michigan sono invece casi delicati. Nei primi due Stati sorgono le due città più popolate dell'intero Paese (New York City e Los Angeles), entrambe caratterizzate da un contesto etnico molto vario, ma non necessariamente omogeneo (basti pensare agli interi quartieri in mano a singoli gruppi etnici) e da molteplici altre problematiche sociali. Il Michigan, invece, ha al suo centro Detroit, città un tempo fulcro della produzione automobilistica nazionale (*Motown*), caduta poi in profonda crisi dopo la chiusura delle fabbriche negli anni '70 e '80, con conseguenti picchi di disoccupazione e povertà ².

In conclusione, l'analisi risulta soddisfacente nel suo obiettivo di fornire una valida interpretazione dei fattori socio-economici che influenzano la criminalità statunitense; essa fornisce inoltre alcuni modelli validi per la previsione e classificazione dei delitti date le caratteristiche delle comunità.

6.1 Limiti dell'analisi ed NA

Il principale ostacolo di questa indagine era rappresentato dall'elevata presenza di valori mancanti per le varie osservazioni. Se per le variabili LEMAS è stato facile rimuovere l'intera sezione corrispondente nel dataset, in quanto del tutto inaffidabile a fini previsivi, lo stesso non si può dire per gli NA relativi alla variabile *rapesPerPop* e, di conseguenza, anche a *ViolentCrimesPerPop*. In questo caso, infatti, si presentavano due problemi: le osservazioni da eliminare sarebbero state circa 200 e, siccome queste si concentravano in specifici Stati, l'analisi risultante non sarebbe stata valida per l'intera parte continentale degli USA ³.

In fase di "ricostruzione" dei valori mancanti, si è anche valutato di utilizzare la *Bayesian Component Analysis*, che tuttavia è stata scartata a favore dell'algoritmo *KNN*, più facilmente giustificabile con l'idea che le comunità "vicine" a livello di covariate del dataset abbiano tassi di stupri simili. Questa assunzione, tuttavia, presenta un grosso limite: impone una struttura di somiglianza tra comunità "vicine" in termini di *KNN*, sacrificando la variabilità "interna" del fenomeno nel singolo gruppo. Ne risultano quindi modelli che sottostimano gli standard error delle previsioni, risultando sostanzialmente troppo "ottimisti".

References

- [1] Bureau of Justice Statistics. *Law Enforcement Management and Administrative Statistics (LEMAS)*. 1990. URL: <https://bjs.ojp.gov/data-collection/law-enforcement-management-and-administrative-statistics-lemas>.
- [2] Federal Bureau of Investigation. *Uniform Crime Reporting (UCR) Program*. 1995. URL: <https://ucr.fbi.gov>.
- [3] Michael Redmond. *Communities and Crime Unnormalized*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5PC8X>. 2009.

²Detroit ha dichiarato bancarotta nel 2013.

³Si ricorda che l'analisi non considera Alaska ed Hawaii, sia per la loro sostanziale differenza dal resto degli USA, sia per l'assenza di osservazioni.